

Communications Numériques

David Darras

02/03/2024

But du cours : Transmettre un message binaire sur un canal physique en minimisant le temps de communication, la probabilité d'erreurs, la bande passante, etc.

1 Théorie de l'information

- La théorie de l'information est liée aux domaines de la **compression** et de la **transmission** des données.
- L'**entropie** d'une variable aléatoire X avec une fonction de masse de probabilité $p(x)$ est définie par :

$$H(X) = - \sum_x p(x) \log_2(p(x)) .$$

Elle représente le nombre de bits en moyenne requis pour décrire la variable aléatoire.

Exemple: Pour un alphabet de 32 symboles équiprobables, l'entropie est de 5bits.

- Plus un symbole a une grande fréquence, moins de bits seront nécessaires pour le coder et inversement, moins un symbole apparaît fréquemment et plus il faudra de bits pour le décrire.

Analogie avec le code morse : La lettre la plus fréquente, le E est codée par ". .", tandis que la moins fréquente le Q est codé par "--. -".

2 Compression de l'information

- **Longueur moyenne d'un code :**

$$L(c, S) = \sum_{a \in A} p(a) \times |c(a)|$$

Donc, en moyenne, il faut $nL(c, S)$ bits pour coder un mot de longueur n de S .

3 Les codes linéaires

- Un n -code est un ensemble de mots binaires tous de longueur n .
Exemple:
- Un (n, k) code est un code de 2^k mots binaires tous de longueur n .
- Un code systématique est un (n, k)

Codage de Huffman

- En physique, pour comparer x et y (de même unité), il suffit de les diviser et de regarder le rapport.

- Rappels de maths discrètes:

$$- \log_b(x) = \frac{\ln(x)}{\ln(b)} = k \iff x = b^k$$

- Soit Σ un alphabet. Alors $Card(\Sigma^n) = Card(\Sigma)^n$.

- On dit qu'un code est **préfixe** si aucun mot du code $c(\Sigma)$ n'est préfixe d'un autre mot du code. Dès lors, tout code préfixe est à déchiffrement unique et tout code à longueur fixe est préfixe.

- La longueur d'un code à longueur fixe sur $\{\sigma_1, \dots, \sigma_n\}$ pour coder les symboles d'un alphabet à m symboles est : $\lceil \log_n(m) \rceil$

- L'**entropie** représente la quantité d'information moyenne par symbole.

- Le codage entropique permet d'éliminer les redondances.

- On note $S = (A, p)$ une **source de symboles indépendants identiquement distribués** avec A un alphabet fini et $p : A \rightarrow [0, 1]$ une distribution de probabilité sur A vérifiant $\sum_{a \in A} p(a) = 1$

- **Quantité d'information** propre d'un symbole a : $I(a) = -\log_2(p(a))$. Dès lors, plus le symbole a une probabilité faible est plus I sera grand.
 $I(a_1 \dots a_n) = I(a_1) + \dots + I(a_n)$.

- **Entropie de Shannon :**

$$H(S) = \sum_{a \in A} p(a) \times I(a) = - \sum_{a \in A} p(a) \times \log_2(p(a))$$

- **Entropie d'Hartley :** $\log_2(Card(A))$ bit / Shannon.

- Inégalité : $0 \leq H(S) \leq \log_2(Card(A))$.

Remarque: On a égalité pour une distribution uniforme.

- **Théorème du codage de Shannon :**

$$H(S) \leq L(c, S)$$

et

il existe un code préfixe entropique (celui de Huffman)

c^* tel que $H(S) \leq L(c^*, S) \leq H(S) + 1$

- **L'efficacité du code** : $\frac{H(S)}{L(c, S)}$ représente l'information transmise par bit transmis.

- **L'Algorithme de Huffman** donne un codage entropique.

1. on mets chacune des lettres dans une feuille avec leur fréquence d'apparition (ou proba) respective dans le texte.
2. On prends les deux noeuds possédant la plus petite proba et on le fait descendre d'un meme noeud, le parent aura comme proba la somme de ses deux fils.
3. On recommence 2) jusqu'à ce que tous le neuods soit accessible depuis une racine.
4. On assigne au branche droite un 1 et aux branches gauches un 0 pour pouvoir construire la table de codage.

- **Codage par bloc** : Au lieu d'attribuer un codage à chaque lettre. On décide d'attribuer un codage par groupe de lettre.

Code en bloc linéaire

- Contrairement à la compression, le but ici de rajouter de la redondance pour détecter et/ou corriger des erreurs.
- Un code en bloc transforme chaque bloc de k 'el'ements binaires en un bloc de n 'el'ements binaires, avec $n \geq k$.
- Dans $\mathbb{Z}/2\mathbb{Z}$ est un corps : $1+1 = 0$ comme le xor = addition modulo 2
- Syndrome : $s = m.H^T$.
- On note d la distance minimale d'un code : $d = \min_{(x,y) \in C \times C, x \neq y} d_H(x, y)$
- **Pouvoir de correction** : $\lfloor \frac{d-1}{2} \rfloor$ erreurs.
- **Pouvoir détection du code** : $d - 1$ erreurs.

Code de Hamming

- C'est un code liénaire (n, k)
- Il vérifie $2^p \geq n + p + 1$
- On veut transmettre $x = x_1 x_2 x_3 x_4$.

- Le message reçu est

$$m = m_1 m_2 m_3 m_4 m_5 m_6 m_7 = p_1 p_2 x_1 p_3 x_2 x_3 x_4$$

On positionne les bits de redondance sur les puissances de 2.

- Pour calculer les bits de redondance

i, m_i	p_3	p_2	p_1
1	0	0	1
2	0	1	0
3	0	1	1
4	1	0	0
5	1	0	1
6	1	1	0
7	1	1	1

$$\begin{aligned} p_1 &= m_1 = m_3 \oplus m_5 \oplus m_7 = x_1 \oplus x_2 \oplus x_4 \\ p_2 &= m_2 = m_3 \oplus m_6 \oplus m_7 = x_1 \oplus x_3 \oplus x_4 \\ p_3 &= m_4 = m_5 \oplus m_6 \oplus m_7 = x_2 \oplus x_3 \oplus x_4 \end{aligned}$$

- Pour vérifier le message reçu, on pose le syndrome

$$\begin{aligned} s_1 &= m_1 \oplus m_3 \oplus m_5 \oplus m_7 \\ s_2 &= m_2 \oplus m_3 \oplus m_6 \oplus m_7 \\ s_3 &= m_4 \oplus m_5 \oplus m_6 \oplus m_7 \end{aligned}$$

Si $s = 0$ alors il aucun bit n'a été modifié. Si $s \neq 0$, alors il faut modifier le $(s)_{10}$ bit pour retrouver le message d'origine.

- Construction de la matrice génératrice:

$G = [I_4 \mid P_1 \mid P_2 \mid P_3]$ avec les vecteurs colonnes $P_1 = (1, 1, 0, 1)$, $P_2 = (1, 0, 1, 1)$ et $P_3 = (0, 1, 1, 1)$. La matrice identité permet de réécrire le message et les matrices P_i permettent de calculer les bits de redondances placés là, à la fin du message.

$$p_1 = 1.x_1 \oplus 1.x_2 \oplus 0.x_3 \oplus 1.x_4 \longrightarrow P_1 = (1, 1, 0, 1)$$

$$G = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{bmatrix}$$

- Matrice de transfert
- Rendement : $R = \frac{k}{n} = 1 - \frac{r}{2^r - 1}$, se rapproche de 1 plus le message sera long.

Code CRC

- C'est un code cyclique systématique.
- Message de base $m = 10011101$.
- On se donne $G(X) = X^4 + X^2 + X + 1$ le polynome générateur de degré 4. On pose $g = 10111$ sa version binaire.

- On rajoute alors à m , quatre 0 : $m' = 10011101.0000$, puis on fait la division euclidienne de m' par g . Ici, on ne fait pas une division euclidienne classique, on utilise l'opérateur XOR, donc il n'y a pas de reste, de soustraction, etc. Dès lors, $1 \oplus 0 = 1$, $0 \oplus 0 = 0$, $1 \oplus 1 = 0$. Le reste de cette division donnera le CRC. On itère jusqu'à tomber à 4 bits

```

100111010000
10111
-----
001001010000
 10111
-----
   0010110000
    10111
-----
     00001000
-----
      CRC=1000

```

Finalement le message envoyé sera : 10011101.1000

- Pour vérifier le message reçu r , on fait la division euclidienne de r par g . Si le reste est nulle alors tout est bon, sinon un ou plusieurs bits on était altéré, on ne peut pas dire lesquels.

```

100111011000
10111
-----
001001011000
 10111
-----
   0010111000
    10110
-----
     00000000 -> Pas d'erreur

```

- Attention à choisir un polynôme générateur de degré d assez grand car pour une erreur en rafale de longueur L , on a : Si $L \leq d$, on a 100% de chance de détecter l'erreur Si $L = d + 1$, on a $100(1 - (1/2)^{(d-1)})$ Si $L \geq d + 1$, c'est $100(1 - (1/2)^{(d)})$