

Évaluation de Performances


David Darras

Date de création : 30/01/2025
Dernière modification : 22/03/2025

1 Rappels sur les probabilités

- **Loi de Poisson** : Soient $\lambda > 0$ et $X \sim \mathcal{P}(\lambda)$. Alors, $X(\Omega) = \mathbb{N}$ et $\forall k \in X(\Omega), P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$.
De plus, $\mathbb{E}[X] = \mathbb{V}[X] = \lambda$.
Remarque : Si $X_1 \sim \mathcal{P}(\lambda_1), \dots, X_n \sim \mathcal{P}(\lambda_n)$ sont indépendantes alors $\sum_{i=1}^n X_i \sim \mathcal{P}(\sum_{i=1}^n \lambda_i)$.
- **Loi géométrique** : Soient $p \in]0, 1[$ et $X \sim \mathcal{G}(p)$. Alors, $X(\Omega) = \mathbb{N}^*, \forall k \in X(\Omega), P(X = k) = (1 - p)^{k-1} p$ et $\forall k \in X(\Omega), P(X > k) = (1 - p)^k$.
De plus, $E[X] = \frac{1}{p}$ et $V[X] = \frac{1-p}{p^2}$.
Remarque : Si $X_1 \sim \mathcal{G}(p_1), \dots, X_n \sim \mathcal{G}(p_n)$ sont indépendantes alors $\min_{1 \leq i \leq n} X_i \sim \mathcal{G}(1 - \prod_{i=1}^n (1 - p_i))$.
- **Loi exponentielle** : Soient $\lambda > 0$ et $X \sim \mathcal{E}(\lambda)$. Alors, $X(\Omega) = \mathbb{R}^+, \forall x \in X(\Omega), f_X(x) = \lambda e^{-\lambda x}$ et $\forall x \in X(\Omega), F_X(x) = 1 - e^{-\lambda x}$.
De plus, $\mathbb{E}[X] = \frac{1}{\lambda}$ et $\mathbb{V}[X] = \frac{1}{\lambda^2}$.
Remarque : Si $X_1 \sim \mathcal{E}(\lambda_1), \dots, X_n \sim \mathcal{E}(\lambda_n)$ sont indépendantes alors $\min_{1 \leq i \leq n} X_i \sim \mathcal{E}(\sum_{i=1}^n \lambda_i)$.
- Les lois géométrique et exponentielle sont dites **sans mémoire**. Dès lors, $P(X > x + y \mid X > x) = P(X > y)$ et $\mathbb{E}[X > x + y \mid X > x] = \mathbb{E}[X > y]$.

2 Introduction aux systèmes de files d'attente



- **Objectif** : Étudier le temps moyen d'attente des clients/tâches (*jobs*) dans un système de files d'attente pour recevoir un service fourni par un ou plusieurs serveurs. On pourra notamment calculer le temps moyen passé dans le système complet (ou juste la file d'attente), le nombre moyen de clients, le taux d'activité du système, etc.
Objectif final : Optimiser le temps moyen de service et le nombre nécessaire de serveurs à mettre en place.
- **Description du système** : Les clients arrivent un par un dans la file d'attente et attendent d'être servis. Si la file est vide, le client est immédiatement servi par le serveur. Si elle est pleine, le client attend son tour. Lorsque le service est rendu, le client quitte immédiatement le système.
Le système est caractérisé par : le mode d'arrivée des clients dans le système, la politique de service (*Service Order*) comme FIFO/FCFS, le nombre de serveurs, etc.
- **Paramètres** :

Notation	Description
$A(t)$	Variable aléatoire donnant le nombre de clients arrivés dans le système dans l'intervalle de temps $[0, t[$.
$D(t)$	Variable aléatoire donnant le nombre de clients partis du système dans l'intervalle de temps $[0, t[$.

$X(t) = A(t) - D(t)$ (resp. $X_q(t)$)	Variable aléatoire donnant le nombre de clients dans le système (resp. la file d'attente) à l'instant t (ceux dans la file d'attente et ceux qui sont en train d'être servis par le serveur).
$(I_n)_{n \geq 1} = (\tau_n - \tau_{n-1})_{n \geq 1}$	Suite de variables aléatoires indépendantes et identiquement distribuées correspondant à l'intervalle séparant l'arrivée de deux clients successifs (inter-arrivées). On note τ_n , le temps auquel le n -ième client est arrivé.
$\mathbb{E}[I] = \frac{1}{\lambda}$	Temps moyen séparant deux inter-arrivées (<i>Mean Interarrival Time</i>).
λ	Nombre moyen de clients arrivant dans le système par unité de temps, soit le taux moyen d'arrivée des clients (<i>Average Arrival Rate</i>).
$(S_n)_{n \geq 1}$	Suite de variables aléatoires indépendantes et identiquement distribuées correspondant au temps de service pour le n -ième client.
$\mathbb{E}[S] = \frac{1}{\mu}$	Temps moyen de service (<i>Mean Service Time</i>).
μ	Nombre moyen de clients servis par le serveur par unité de temps, soit le taux moyen de service (<i>Average Service Rate</i>).
$p_n(t) = P(X(t) = n)$	Probabilité d'observer n clients dans le système à l'instant t .
$p_n = P(X = n)$	Probabilité asymptotique (ou limite) qu'il y ait n clients dans le système en régime stationnaire (= état d'équilibre atteint après un grand intervalle de temps T), $p_n = \lim_{t \rightarrow +\infty} P(X(t) = n)$
$\bar{L}_s = \mathbb{E}[X] = \sum_{n \geq 0} n p_n$	Nombre moyen asymptotique de clients dans le système en régime stationnaire.
$\bar{L}_q = \mathbb{E}[X_q] = \sum_{n > c+1} (n - c) p_n$	Nombre moyen asymptotique de clients dans la file d'attente.
$\bar{W}_s = \bar{W}_q + \mathbb{E}[S]$ (resp. $\bar{W}_q$)	Temps moyen asymptotique de séjour qu'un client passe dans le système (resp. dans la file d'attente).
$a_n(t)$ (resp. $d_n(t)$)	Probabilité qu'un client arrive dans (resp. quitte) le système au temps t et y trouve (resp. laisse) n clients. On note $a_n = \lim_{t \rightarrow +\infty} a_n(t)$ et $d_n = \lim_{t \rightarrow +\infty} d_n(t)$ les probabilités asymptotiques associées
$\rho = \frac{\lambda}{c\mu}$	Intensité du trafic
$U = 1 - p_0$	Taux d'activité du système.
$\bar{U} = p_0$	Taux d'inactivité du système.

- **Notation de Kendall** : $I/S/c/K$: Elle permet de caractériser un système de manière brève.
 - I : Loi des inter-arrivées des clients (donnée par une variable aléatoire en unité de temps).
 - S : Loi du service (donnée par une variable aléatoire en unité de temps).
 - c : Nombre de serveurs.
 - K : Capacité du système d'attente, c'est-à-dire le nombre maximal de clients pouvant attendre dans la file. On pose souvent $K = +\infty$ pour un système ouvert.

Pour I et S , on retrouve souvent M pour *Memoryless* qui désigne une **loi exponentielle**. Tandis que G désigne une file d'attente générale sans loi précise.

- **Théorème de Burke** : Pour un système quelconque en **régime stationnaire** dont les arrivées et les départs se font un par un, on a pour tout $n \geq 0$, $a_n = d_n$.

- **Formule de Little** : $\bar{L} = \lambda \bar{W}$.

Remarque : La formule fonctionne pour $L = L_s$ et $W = W_s$, ou bien $L = L_q$ et $W = W_q$.

- **Condition de stabilité** : $\rho < 1 \iff \lambda < \mu$.

Remarque : Si $\rho \geq 1$, alors le nombre de clients en attente de recevoir un service augmente indéfiniment. Or, si $\rho < 1$, le système est stable et il est possible d'étudier le régime stationnaire.

3 Chaînes de Markov à temps discret

- On considère un système dont l'état évolue au cours du temps de manière aléatoire, décrit par une famille de variables aléatoires $(X_n)_{n \geq 0}$ à valeurs dans E , un ensemble d'états. Le système évolue par étapes et reste donc dans le même état durant l'intervalle de temps $[t_n; t_{n+1}[$.

Exemple : Pour les files d'attente, on peut prendre $E = \mathbb{N}$ pour enregistrer en mémoire combien de clients sont dans le système. Dès lors, être dans l'état 5 signifie qu'il y a 5 clients dans le système.

- La distribution de $(X_n)_{n \geq 0}$ est donnée par le vecteur :

$$\pi(n) = (\pi_0(n), \dots, \pi_N(n), \dots) = (P(X_n = 0), \dots, P(X_n = N), \dots)$$

$\pi_k(n) = P(X_n = k)$ désigne la probabilité pour que le système se trouve dans l'état k à l'étape de temps n .

- **Condition de normalisation** : $\forall n \in \mathbb{N}, \sum_{k \in E} \pi_k(n) = 1$

- On dit que la suite $(X_n)_{n \geq 0}$ de variables aléatoires (aussi connue sous le nom de **processus stochastique**) à valeurs dans E est une **chaîne de Markov homogène** si : $\forall n \in \mathbb{N}, \forall i, j \in E, \forall (x_0, \dots, x_{n-1}) \in E^n$,

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = P(X_{n+1} = j \mid X_n = i) = P(X_1 = j \mid X_0 = i) = p_{i,j}$$

En d'autres termes, à l'étape n , le système passe de i à l'état j avec une probabilité qui ne dépend que de l'état courant (les états passés sont ignorés). De plus, on dit qu'elle est homogène car elle ne dépend pas de l'étape n à laquelle on se situe.

Remarque : Si $(X_n)_{n \geq 0}$ a besoin de l'état courant et de son état intérieur, alors ce n'est pas une chaîne de Markov, mais il suffit de poser $Y_n = (X_n, X_{n-1})$ pour en avoir une. On sauvegarde en mémoire l'information manquante.

- Dès lors, toutes les transitions de l'automate peuvent être stockées dans une **matrice de transitions** sur l'espace d'états E : $P = (p_{i,j})_{0 \leq i,j \leq N}$.

Remarque : Pour toute ligne $i \in E$, $\sum_j p_{i,j} = 1$ et $\forall j \in E, p_{i,j} \geq 0$.




- **Exemple** : Pour $P = \begin{pmatrix} p^2 & 2p(1-p) & 1-p^2 \\ 0 & p & 1-p \\ 0 & 0 & 1 \end{pmatrix}$, on a

le **graphe de transitions** ci-contre.

Remarque : La transition $(0) \dashrightarrow (2)$ signifie qu'il y a une probabilité de $p_{0,2} = P(X_{n+1} = 2 \mid X_n = 0) = (1-p)^2$ de passer de l'état 0 à l'état 2. On remarque que la somme des probabilités des arcs sortant (resp. entrant) doit être égale à 1.

- On dit qu'un état x est **récurrent** si en partant de x on retourne à x presque sûrement (c'est-à-dire avec probabilité 1). À l'inverse, on dit qu'un état x est **transitoire** s'il est possible (donc avec une probabilité non nulle) de ne jamais y retourner après l'avoir quitté.
- On dit qu'une chaîne de Markov homogène est **ergodique** si elle est irréductible, récurrente positive et apériodique.

- Irréductible : Il existe un chemin entre chaque paire d'états.
- Récurrente positive : Chaque état est revisité avec probabilité 1.
- Apériodique : Il n'y a pas de cycles de longueur fixe entre les états.



- **Étude asymptotique** : Sous réserve d'existence, π est l'unique distribution stationnaire de P vérifiant $\pi = \pi P$ et $\sum_{k \in E} \pi_k = 1$. Par exemple, une chaîne de Markov homogène irréductible admet une distribution stationnaire si et seulement si tous ses états sont récurrents positifs et apériodiques.

- **Astuce n°1** : On ne va pas s'amuser à faire le produit matriciel $\pi = \pi P$ pour trouver π . On utilise plutôt l'équation de bilan suivante, aussi appelée **Global balance equation** :

$$\text{Flux sortant de l'état } i = \text{Flux entrant dans l'état } i$$

$$\sum_{j \neq i} \pi_i P_{i,j} = \sum_{j \neq i} \pi_j P_{j,i}$$

Exemple : Si on prend la première chaîne irréductible apériodique ci-dessus, on a :

$$\begin{cases} \pi_1 \frac{1}{2} = \pi_2 \frac{2}{3} & (\text{état 1}) \\ \pi_2 \frac{2}{3} = \pi_1 \frac{1}{2} & (\text{état 2}) \end{cases}$$

Remarque : Les rebouclages (c'est-à-dire la transition d'un état à lui-même) ne sont pas pris en compte !

Après avoir résolu le système d'équations en trouvant une équation de récurrence par exemple $\pi_k = f(k)$, on utilise la **condition de normalisation** $\sum_{i \in E} \pi_i = 1$ afin de trouver la valeur $\pi(0)$.

- **Astuce n°2 :** On peut supposer qu'on a une chaîne de Markov à temps réversible et utiliser l'**équation de réversibilité** :

$$\pi_i P_{i,j} = \pi_j P_{j,i}$$

avec encore une fois la condition de normalisation.

- **Astuce n°3 :** Pour vérifier (et même démontrer) qu'on a bien trouvé le bon π , il suffit de l'injecter dans la *global balance equation* et de vérifier que l'on obtient bien l'égalité.

4 Chaînes de Markov à temps continu

- Pour modéliser mathématiquement nos files d'attente, on préfère utiliser des chaînes de Markov à temps continu car l'état peut changer à n'importe quel instant, ce qui est plus réaliste que les chaînes de Markov à temps discret où tout est synchronisé. La définition est à peu près la même :

$$P(X(t+s) = j \mid X(s) = i, X(u) = x(u), 0 \leq u \leq s) = P(X(t+s) = j \mid X(s) = i) = P(X(t) = j \mid X(0) = i) = P_{i,j}(t)$$

Or, il devient impossible d'étudier un objet aussi compliqué.

- **Attention :** Pour que la modélisation soit correcte, il faut que le temps passé dans un état i avant la transition suive une **loi exponentielle** ! Quand il quitte l'état i pour aller dans l'état j , cela doit se faire avec une probabilité $p_{i,j}$ indépendante du temps passé dans l'état i !
- Ici, on ne s'intéresse plus à P mais à Q , appelé le **générateur infinitésimal**. On ne met plus des probabilités sur les transitions mais des taux (des vitesses de transition). Dès lors, la somme des scalaires d'une ligne doit valoir 0 et non 1 !
- Sous réserve d'existence, π est l'unique solution à constante près de l'équation de Q vérifiant $\pi Q = 0$.
La **global balance equation** est toujours valide :


$$\sum_{j \neq i} \pi_i Q_{i,j} = \sum_{j \neq i} \pi_j Q_{j,i}$$

ainsi que la **condition de normalisation**.

5 Processus de naissance et de mort

On dit qu'un processus stochastique est un **processus de naissance et de mort** si son générateur infinitésimal est de la forme suivante :

$$\begin{cases} Q_{n,n+1} = \lambda_n \\ Q_{n,n-1} = \mu_n \\ Q_{n,m} = 0 \text{ si } |n-m| \geq 2 \\ Q_{0,0} = \lambda_0 \\ Q_{n,n} = -(\lambda_n + \mu_n) \end{cases}$$



- La chaîne étant réversible, on a pour tout $n \in \mathbb{N}$, $\lambda_n p_n = \mu_{n+1} p_{n+1}$. Dès lors, par récurrence descendante,

$$\boxed{\forall n \in \mathbb{N}, p_n = \frac{\lambda_0 \dots \lambda_{n-1}}{\mu_1 \dots \mu_n} p_0} \text{ avec } \boxed{p_0 = \frac{1}{1 + \sum_{n=1}^{+\infty} \frac{\lambda_0 \dots \lambda_{n-1}}{\mu_1 \dots \mu_n}}} \text{ d'après la condition de normalisation.}$$

- Remarque** : Ce processus est valable pour des systèmes de files d'attente de type M/M/c. De plus, il est impossible que deux événements (arrivée ou départ) se produisent exactement au même temps t , d'où $Q_{n,m} = 0$ pour $|n - m| \geq 2$.

6 Processus de Poisson

- Un processus de Poisson d'intensité $\lambda > 0$ est un processus de comptage $\{N(t); t \geq 0\}$ vérifiant :


- $N(0) = 0$
- $\forall 0 \leq t_0 \leq \dots \leq t_n$, $N(t_{i+1}) - N(t_i)$ sont des variables indépendantes.
- $\boxed{\forall t \geq 0, \forall s > 0, N(t+s) - N(t) \sim \mathcal{P}(\lambda s)}$
- $\boxed{\forall t > 0, N(t) \sim \mathcal{E}(\lambda t)}$.

- Si on considère un processus de Poisson d'intensité $\lambda > 0$ pour notre système de file d'attente, alors $\forall n \in \mathbb{N}$, $\boxed{I_n \sim \mathcal{E}(\lambda)}$ et $\boxed{S_n \sim \mathcal{E}(\mu)}$.


Remarque : On considère souvent l'arrivée comme un processus de Poisson car sous certaines conditions, une superposition de processus de renouvellements indépendants se comporte comme un processus de Poisson.

- Propriétés**

Décomposition d'un processus Poisson avec $\sum_{i=1}^n p_i = 1$



Superposition de processus Poisson avec $\lambda = \sum_{i=1}^n \lambda_i$



- Propriété PASTA** (*Poisson Arrivals See Time Averages*) : Pour un processus de Poisson, on a : $\boxed{\forall n \geq 0, a_n = p_n}$.
- Théorème (Burke)** : Dans un système d'attente M/M/c, en régime permanent, le processus de départ est un processus de Poisson de même intensité λ que celui des arrivées.

7 Systèmes de files d'attente M/M/1 et M/M/∞

- On remarque que $\{X(t); t \geq 0\}$ est un processus de naissance et de mort avec $\forall n \in E, \lambda_n = \lambda$ et $\forall n \in E, \mu_n = \mu$. Dès lors, la distribution stationnaire est donnée par : $\forall n \geq 0, \pi_n = \left(\frac{\lambda}{\mu}\right)^n \pi_0$ avec $\sum_{n=0}^{+\infty} \pi_n = 1$. Dès lors, on retrouve notre condition de stabilité car pour que la série $\sum_{n \geq 0} \left(\frac{\lambda}{\mu}\right)^n$ converge, il faut que $\frac{\lambda}{\mu} < 1$.
- La distribution stationnaire est la **loi géométrique** de paramètre ρ . De plus, $W_s \sim \mathcal{E}(\mu - \lambda)$ et $\overline{L_s} = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}$.
- Avec le même raisonnement, on trouve que pour une file d'attente de type M/M/∞, la distribution stationnaire suit une **loi de Poisson** de paramètre ρ .

8 Les réseaux de files d'attente

...

9 Références

